

Energy based models

Студенты группы 5030102/20202:
Бурлака Никита
Диденко Евгений
Тишковец Сергей

План презентации

- Причина появления EBM
- Основная идея
- Формулировка задачи
- Обучение модели
- Практические примеры
- Перспективы развития
- Список литературы

Причины появления EBM

Проблемы классического подхода (классификация, регрессия):

Жесткая архитектура: под каждую задачу — своя модель

Один правильный ответ

Сложно работать с **неоднозначными данными**

Что делать, если нужна модель, которая:

Может оценить **любую гипотезу** Y для данного входа X

Понимает, что на один вопрос может быть **несколько "правильных" ответов**

Применима к **разным задачам** без изменения фундаментального принципа

Решение:

Вместо того чтобы учиться предсказывать Y , модель научится оценивать, насколько хорошо Y подходит к X

Основная идея EBM

Энергии $E(X, Y)$:

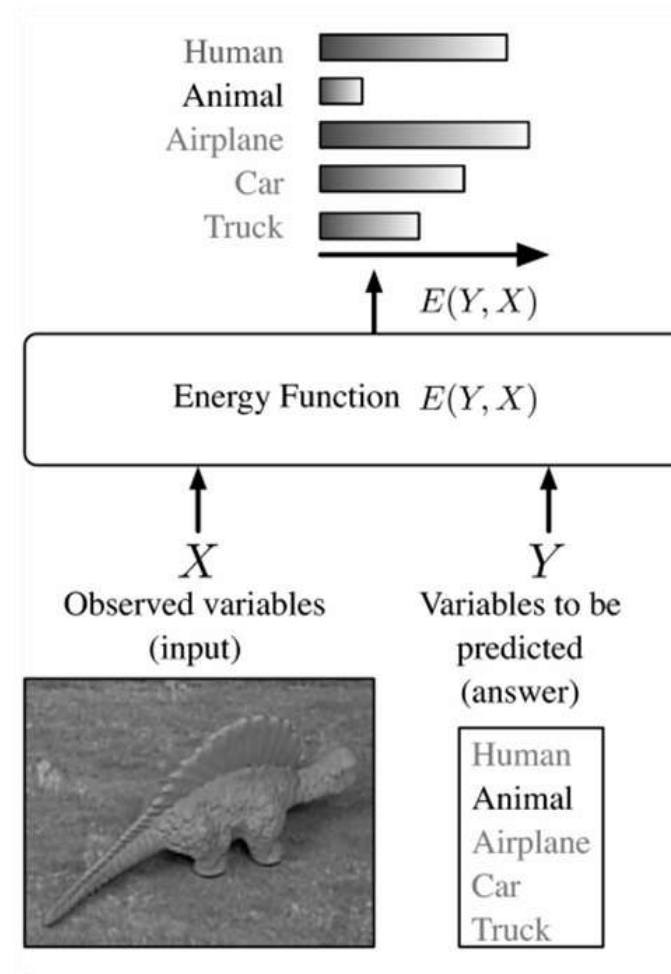
- Это скалярная функция
- Показывает **совместимость** X и Y
- **Вход:** Любой объект X (изображение, текст) и любая гипотеза Y (метка, текст, картинка)
- **Выход:** Число — "Энергия", которая показывает совместимость пары (X, Y)

Ключевой принцип:

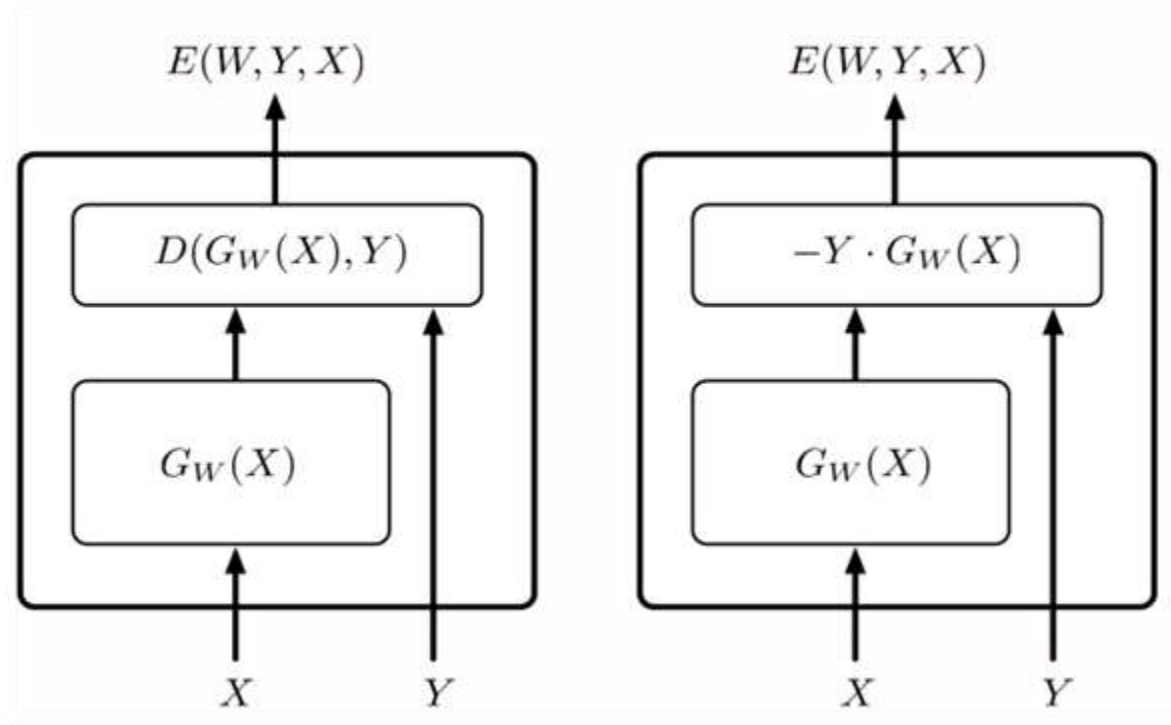
- Низкая энергия = Высокая совместимость
- Высокая энергия = Низкая совместимость

Этапы работы:

- Обучение (train) — настройка параметров модели (функция $E(X, Y)$)
- Вывод (inference) — поиск $Y^* = \operatorname{argmin}(E(X, Y))$



Формулировка задач в рамках EBM



Регрессия

$$E(W, Y, X) = \frac{1}{2} \|G_W(X) - Y\|^2.$$

Классификация

$$E(W, Y, X) = -Y G_W(X)$$

Формулировка вероятностной модели

- $E(X,Y)$ — скалярное число, однако оно **не дает возможности определить вероятность $P(Y|X)$**
- В этом случае переход к распределению Гиббса позволяет перейти к вероятностной модели

$$P(Y|X) = \frac{e^{-\beta E(Y,X)}}{\int_{y \in \mathcal{Y}} e^{-\beta E(y,X)}},$$


partition function

Inverse temperature

Возможности этой парадигмы

- Скрытая регрессия
- Для одного и того же X может быть несколько Y

$$E(W, X, Y) = \|G_{1w_1}(X) - G_{2w_2}(Y)\|_1$$



Способы обучения модели

$$\mathcal{L}(E, \mathcal{S}) = \frac{1}{P} \sum_{i=1}^P L(Y^i, E(W, \mathcal{Y}, X^i)) + R(W).$$

Per-sample loss Desired answer Energy surface for a given X^i as Y varies Regularizer

$$L_{energy}(Y^i, E(W, \mathcal{Y}, X^i)) = E(W, Y^i, X^i)$$

$$L_{perceptron}(Y^i, E(W, \mathcal{Y}, X^i)) = E(W, Y^i, X^i) - \min_{Y \in \mathcal{Y}} E(W, Y, X^i)$$

Коллапс обучения

Условие корректного инференса

$$E(W, Y^i, X^i) < E(X, Y, X^i), \forall Y \in \mathcal{Y} \text{ and } Y \neq Y^i.$$

Решение — более устойчивое условие на инференс


$$E(W, Y^i, X^i) < E(W, \bar{Y}^i, X^i) - m.$$

Адаптированный лосс

$$E(W, Y^i, X^i)^2 - (\max(0, m - E(W, \bar{Y}^i, X^i)))^2$$


Что если $G_1 = G_2$ для любых X и Y

$$E(W, X, Y) = \|G_{1w_1}(X) - G_{2w_2}(Y)\|_1$$



Inference для категориальных величин

Для конечного числа кат. величин можно перебором посчитать все значения энергий



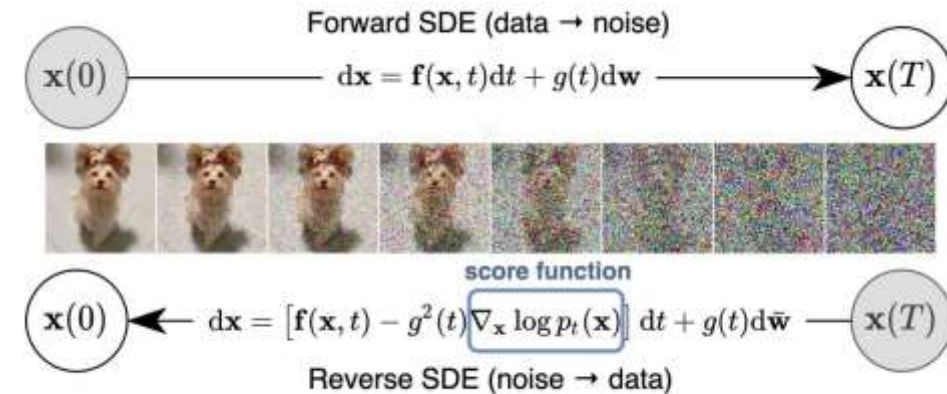
Разложение в фактор граф позволяет сузить область перебора

$$E(Y, Z, X) = E_a(X, Z_1) + E_b(X, Z_1, Z_2) + E_c(Z_2, Y_1) + E_d(Y_1, Y_2),$$

$$(\bar{Y}, \bar{Z}) = \operatorname{argmin}_{y \in \mathcal{Y}, z \in \mathcal{Z}} (E_a(X, z_1) + E_b(X, z_1, z_2) + E_c(z_2, y_1) + E_d(y_1, y_2))$$

Современные EBM в Computer Vision

- **Score-based генеративная модель**
- Модель учит score — направление, куда двигаться, чтобы попасть в более «правдоподобную» область.
- Параметр шума : при больших значениях изображение становится размытым, при малых — проявляются детали.
- Генерация - интеграция обратного процесса + коррекция через predictor–corrector.
- Плюсы: не нужен нормировочный множитель, легко комбинировать энергии (удобно для задач восстановления).
- Минусы: семплинг медленный (много шагов), нужно аккуратно задавать шум и веса при обучении.



Перспективы развития

- **Задачи применения:**
 - Структурное предсказание (сегментация, разметка)
 - Генерация (изображения, текст)
- **Ограничения:**
 - Сложность обучения и семплирования
 - Высокие вычислительные затраты
 - Трудности с дискретными данными
- **Активные исследования:**
 - Новые алгоритмы обучения
 - Интеграция с диффузионными и физически мотивированными методами
 - Применение в объяснимости и контролируемой генерации

Список литературы

- [Deep Energy-Based Generative Models](#)
- [Лекции от LeeCun](#)
- [Energy-based diffusion language models](#)

Спасибо за внимание