

Временные ряды

Лисицкая Елизавета
Муринов Андрей
Смаева Елизавета

Санкт-Петербургский политехнический университет Петра Великого

17 ноября 2025 г.



1 Временные ряды

2 Аналитика временных рядов

3 Модель вида ARIMA

1 Временные ряды

2 Аналитика временных рядов

3 Модель вида ARIMA

Временные ряды

Определение

Временной ряд — значения меняющихся во времени признаков, полученные в некоторые моменты времени.

Задача прогнозирования

Пусть $(y_t, t \in \mathbb{N})$ - временной ряд, для которого известны значения y_1, \dots, y_T .

Требуется построить прогноз - функцию f , такую что величина

$\hat{y}_{T+h} = f(y_1, \dots, y_T, h)$ как можно лучше приближает значение y_{T+h} , где h - количество шагов на которое нужно построить прогноз.

Иногда требуется построить доверительный интервал (d_{T+h}, u_{T+h}) , т.ч.

$$\mathbb{P}(d_{T_h} \leq y_{T+h} \leq u_{T+h}) \geq \alpha$$

Составляющие временного ряда

В общем случае модель временного ряда имеет вид:


$$y_t = F(d_t, \varepsilon_t),$$

где d_t - систематическая составляющая ряда, ε_t - случайная составляющая ряда, с нулевым математическим ожиданием

Определения

- Тренд - плавное долгосрочное изменение временного ряда.
- Сезонность и цикличность – повторяющиеся изменения временного ряда с постоянным периодом (как правило сезонном считают период меньше года, циклом - больше года)
- Шум - непрогнозируемая случайная компонента ряда.

Декомпозиция ВР



Пусть T_t - тренд, S_t - сезонность, R_t - шум.

- Аддитивная декомпозиция:
 $y_t = T_t + S_t + R_t$
- Мультипликативная декомпозиция:
 $y_t = T_t \cdot S_t \cdot R_t$

Декомпозиция на основе скользящего среднего

Пусть s - известный период сезонности.

- Тренд:

$$T_t = \frac{1}{s} \sum_{i=t-s/2}^{t+s/2} y_i$$

- Сезонность:

$$y_t := y_t - T_t$$


$$G_i = \{y_i, y_{i+s}, \dots, y_{i+ks}\}, \text{ где } i \in [1 : s]$$

$$S_t = \bar{G}_{(t \bmod s)}$$

- Ошибка:

$$R_t = y_t - T_t - S_t$$

Пример декомпозиции



1 Временные ряды

2 Аналитика временных рядов

3 Модель вида ARIMA

Автокорреляционная функция



Временной ряд может содержать зависимые между собой признаки.

Коэффициент корреляции Пирсона ряда с лагом τ

$$r_\tau = \widehat{corr}(y_t, y_{t+\tau}) = \frac{\sum_{t=1}^{T-\tau} (y_t - \bar{y})(y_{t+\tau} - \bar{y})}{\sum_{t=1}^T (y_t - \bar{y})^2},$$

где \bar{y} - среднее всего ряда.

Коррелограмма. Пример.



Стационарные временные ряды

Определение

Временной ряд считается стационарным, если выполняются три условия:

- ① Постоянное математическое ожидание:

$$E(y_t) = \mu \quad \text{для всех } t$$

- ② Постоянная дисперсия:

$$\text{Var}(y_t) = \sigma^2 \quad \text{для всех } t$$

- ③ Ковариация зависит только от сдвига:

$$\text{Cov}(y_t, y_{t+k}) = \gamma_k \quad \text{для всех } t \text{ и любого } k$$

Кросс-валидация для временных рядов

Схемы кросс-валидации

- ① Обучаем модель на первых t значениях, прогнозируем следующие Δt значений
- ② Обучаем модель на $t + \Delta t$ значениях, прогнозируем значения $y_{\Delta t+t}, \dots, y_{t+2\Delta}$
- ③ ...
- ④ На каждой итерации считаем ошибки и усредняем

- ① Обучаем модель на первых t значениях, прогнозируем следующие Δt значений
- ② Обучаем модель на значениях $y_{\Delta t+1}, \dots, y_{\Delta t+t}$, прогнозируем значения $y_{t+\Delta t+1}, \dots, y_{t+2\Delta}$
- ③ ...
- ④ Считаем ошибки и усредняем

1 Временные ряды

2 Аналитика временных рядов

3 Модель вида ARIMA

Приведение временных рядов к стационарности

Методы преобразования

- Дифференцирование:

$$y'_t = y_t - y_{t-1}$$

Устраниет линейный тренд

- Сезонное дифференцирование:

$$y'_t = y_t - y_{t-m}$$

Устраниет сезонность (m - период)

Преобразование Бокса-Кокса:

$$y^{(\lambda)} = \begin{cases} \frac{y^\lambda - 1}{\lambda}, & \lambda \neq 0 \\ \ln(y), & \lambda = 0 \end{cases}$$

Стабилизирует дисперсию

Модель скользящего среднего (МА)

Значение временного ряда в момент t описывается как линейная комбинация прошлых ошибок прогноза (“белого шума”).

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \cdots + \theta_q \varepsilon_{t-q}$$

- Где:
 - y_t — значение ряда в момент t
 - μ — константа (среднее значение ряда)
 - $\varepsilon_t, \varepsilon_{t-1}, \dots$ — ошибки (белый шум), $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$
 - $\theta_1, \dots, \theta_q$ — параметры модели
 - q — порядок модели (MA(q))

Модель авторегрессии (AR)

Значение временного ряда в момент t описывается как линейная комбинация его собственных прошлых значений.

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t$$

- Где:
 - y_t, y_{t-1}, \dots — значения ряда в моменты времени $t, t-1, \dots$
 - c — константа
 - ϕ_1, \dots, ϕ_p — параметры модели
 - ε_t — ошибка (белый шум) в момент t
 - p — порядок модели (AR(p))
- Отметим, что, вообще говоря, для стационарности нужны некоторые условия на коэффициенты

Стационарность AR модели

Характеристическое уравнение

$$1 - \phi_1 z - \phi_2 z^2 - \cdots - \phi_p z^p = 0$$

Условие стационарности для AR(p)

Для AR(p) модели: $y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t$

Модель является стационарной, если все корни характеристического уравнения лежат вне единичного круга.

Модель авторегрессии и скользящего среднего (ARMA)

Комбинирует подходы AR и MA, чтобы использовать преимущества обеих моделей. Значение ряда зависит как от своих прошлых значений, так и от прошлых ошибок прогноза.

$$y_t = c + \phi_1 y_{t-1} + \cdots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

- Где:
 - p — порядок авторегрессионной части (AR)
 - q — порядок части скользящего среднего (MA)
- Обозначается как ARMA(p, q).
- Стационарность модели будет определяться только его AR(p) компонентой

Модель ARIMA(p, d, q)

Определение:

Модель ARIMA(p, d, q) — это расширение моделей типа ARMA на нестационарные временные ряды, которые однако могут стать стационарным после применения процедуры дифференцирования ряда.

Формула:

$$a(L)(1 - L)^d y_t = \alpha + b(L)\varepsilon_t,$$

или

$$(1 - L)^d y_t = \mu + \frac{b(L)}{a(L)}\varepsilon_t.$$

Замечание: многочлен $\tilde{a}(z) = a(z)(1 - z)^d$ имеет d единичных корней \Rightarrow модель позволяет учесть нестационарности, в частности, тренд.

Частичная автокорреляционная функция (PACF)

Определение

Частичная автокорреляция (PACF) — корреляция ряда с собой после снятия линейной зависимости от промежуточных значений ряда.

Цель — учесть опосредованное влияние промежуточных значений и оценить непосредственное влияние $y_{t-\tau}$ на y_t .

Формула

$$\gamma_\tau = \begin{cases} \text{corr}(y_{t+1}, y_t), & \tau = 1; \\ \text{corr}(y_{t+\tau} - y_{t+\tau}^{\tau-1}, y_t - y_t^{\tau-1}), & \tau \geq 2, \end{cases}$$

где $y_t^{\tau-1}$ — линейная регрессия на $y_{t-1}, y_{t-2}, \dots, y_{t-(\tau-1)}$:

- $y_t^{\tau-1} = \varphi_1 y_{t-1} + \varphi_2 y_{t-2} + \dots + \varphi_{\tau-1} y_{t-(\tau-1)}$
- $y_{t+\tau}^{\tau-1} = \varphi_1 y_{t+\tau-1} + \varphi_2 y_{t+\tau-2} + \dots + \varphi_{\tau-1} y_{t+1}$

Оценка коэффициентов в ARIMA

Пусть гиперпараметры p, d, q фиксированы, ε_t — гауссовский белый шум, выпишем функцию правдоподобия:

$$L_y(\theta, \varphi, \alpha) = p_{\theta, \varphi, \alpha}(y_1, \dots, y_T)$$

где $p_{\theta, \varphi, \alpha}(y_1, \dots, y_T)$ — совместная плотность.

В качестве оценок параметров берется оценка максимального правдоподобия.

Для поиска начальных приближений p и q :

- p : последний значимый пик у PACF
- q : последний значимый пик у ACF

Далее используется поиск по сетке, минимизируя информационный критерий:

- $AIC = -2\ell^* + 2(p+q+1)$ — критерий Акаике
- $AIC_c = -2\ell^* + \frac{2(p+q+1)(p+q+2)}{T-p-q-2}$ — для коротких рядов
- $BIC = -2\ell^* + (\log T - 2)(p+q+1)$ — Байесовский информационный критерий

где $\ell^* = \ln L_y(\hat{\theta}, \hat{\varphi}, \hat{\alpha})$ — логарифм функции правдоподобия.

План прогнозирования с помощью модели ARIMA

- ➊ Анализ выбросов: замена нерелевантных выбросов на NA или усреднение по соседним элементам
- ➋ Стабилизация дисперсии с помощью преобразований
- ➌ Дифференцирование, если ряд нестационарен
- ➍ Выбор пилотных p и q по PACF и ACF
- ➎ Подбор оптимальной модели по AIC/AIC_c вокруг этих параметров

- ➏ Пошаговое построение прогноза:
 - для $t \leq T$: $\varepsilon_t = y_t - \hat{y}_t$
 - для $t > T$: $\varepsilon_t = 0$
 - для $t > T$: $y_t = \hat{y}_t$
- ➐ Построение предсказательного интервала:
 - если остатки модели нормальны и гомоскедастичны (дисперсия постоянна), то строится теоретический предсказательный интервал;
 - иначе интервалы строятся с помощью бутстрепа.

Модель SARIMA

Пусть s — известная сезонность ряда. Добавим в модель ARIMA(p,d,q) компоненты, отвечающие за значения в предыдущие сезоны.
SARIMA $(p,d,q) \times (P,D,Q)_s$:

$$(1 - L)^d (1 - L^s)^D y_t = \mu + \frac{b(L)B(L^s)}{a(L)A(L^s)} \varepsilon_t,$$

где

$$a(z) = 1 - \varphi_1 z - \cdots - \varphi_p z^p,$$

$$b(z) = 1 + \theta_1 z - \cdots - \theta_q z^q,$$

$$A(z) = 1 - \varphi_1^s z - \cdots - \varphi_P^s z^P,$$

$$B(z) = 1 + \theta_1^s z - \cdots - \theta_Q^s z^Q.$$

Модель ARIMAX

ARIMAX — обобщение модели ARIMA, которая учитывает некоторые экзогенные факторы. Пусть $x_t \in \mathbb{R}^n$ — ряд регрессоров, известный до начала прогноза.

Простой вариант:

$$(1 - L)^d y_t = \mu + \sum_{i=1}^n \frac{\beta_i}{a(L)} x_t^i + \frac{b(L)}{a(L)} \varepsilon_t$$

Общий случай:

$$(1 - L)^d y_t = \mu + \sum_{i=1}^n \frac{u_i(L)}{v_i(L)} x_t^i + \frac{b(L)}{a(L)} \varepsilon_t$$

Источники

Использованные материалы

- [1] Учебник по машинному обучению.
Яндекс. Хэндбук.
Обзор основных концепций и алгоритмов машинного обучения.

- [2] Сурина А.В. Анализ временных рядов.
СПбПУ. Научно-технические ведомости.
Методы и модели для анализа и прогнозирования временных рядов.

Спасибо за внимание!