

# Машинное обучение

## Логистическая регрессия

Житницкая Ирина гр. 20401  
Черняховский Лев гр. 20202  
Штейнберг Георгий гр. 20202

10.11.25

# Содержание


## ▶ Что такое логистическая регрессия

- ▶ Основная идея
- ▶ Математическая модель
- ▶ Обучение модели
- ▶ Интерпретация результатов

## ▶ Пример применения

## ▶ Преимущества и недостатки

## ▶ Вариации и расширения



# Определение

- ▶ Логистическая регрессия – это статистическая модель, используемая для прогнозирования вероятности возникновения некоторого события путём его сравнения с логистической кривой.




График логистической кривой:  $y = \frac{1}{1+e^{-x}}$

# Математическая модель

---

- ▶ Вероятность того, что объект принадлежит классу  $y = 1$ :
  - ▶  $\mathcal{P}(y = 1|x) = \sigma(z) = \frac{1}{1+e^{-z}}$ ,  
где  $z = a_0 + a_1x_1 + a_2x_2 + \dots + a_nx_n$   
 $x_1, x_2 \dots x_n$  – независимые переменные  
 $a_1, a_2 \dots a_n$  – коэффициенты регрессии  
 $a_0$  – смещение
- ▶  $\mathcal{P}(y_i|x_i) = \sigma(z_i)^{y_i}(1 - \sigma(z_i))^{(1-y_i)}$ 
  - ▶ Если  $y_i = 1$ , то вероятность  $\sigma(z_i)$
  - ▶ Если  $y_i = 0$ , то вероятность  $1 - \sigma(z_i)$

# Математическая модель

---

## ► Логарифмическая функция потерь

Мы хотим подобрать веса  $a_0, a_1 \dots a_n$ , чтобы **правдоподобие данных** было максимальным

$$L(w) = \prod_{i=1}^N \mathcal{P}(y_i | x_i)$$

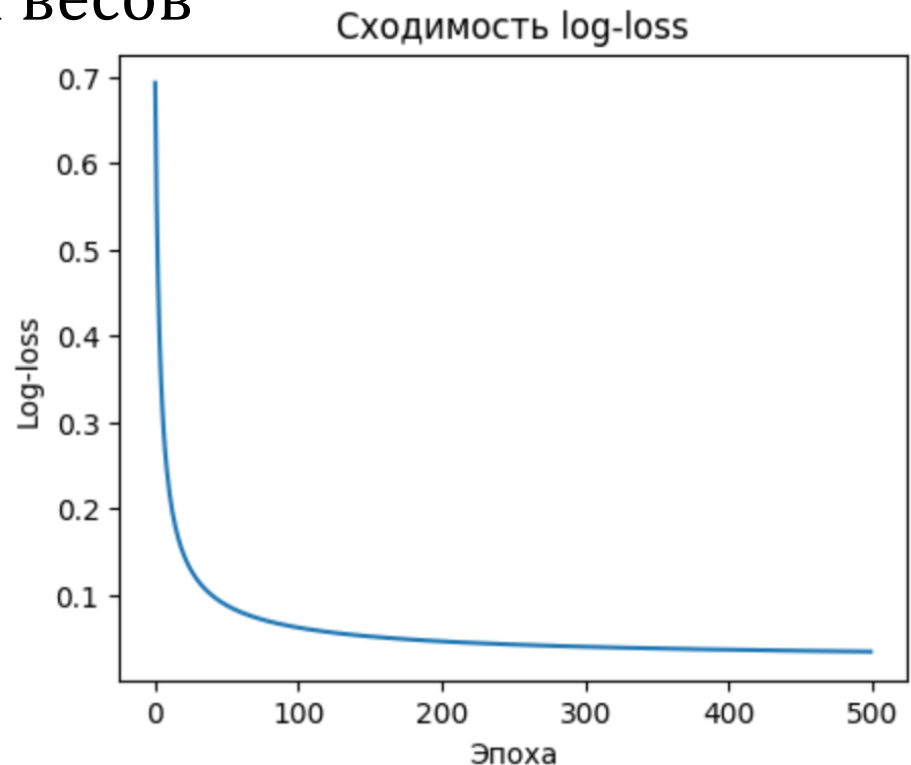
Для удобства используем логарифм:

$$\log L(w) = \sum_{i=1}^N (y_i \log(\sigma(z_i)) + (1 - y_i) \log(1 - \sigma(z_i)))$$

$\mathcal{L}(w) = -\log L(w)$  – это log loss

# Процесс обучения модели

- ▶ Начинаем с произвольных весов  $a_0, a_1 \dots a_n$
- ▶ Используем градиентный спуск для минимизации log loss и корректировки весов
- ▶ Повторяем, пока log loss не станет минимальной



# Интерпретация результатов

---

- ▶ Чтобы принять окончательное решение о принадлежности объекта к классу вводится пороговое значение (обычно 0.5)

$$y = \begin{cases} 1, & \text{если } \mathcal{P} \geq 0.5 \\ 0, & \text{если } \mathcal{P} \leq 0.5 \end{cases}$$

- ▶ Каждый вес  $a_0, a_1 \dots a_n$  показывает влияние признака  $x_1, x_2 \dots x_n$  на вероятность

## Пример

---

► Дано:  $N=3$  наблюдения.  $X=[1, 2, 3]$   $Y=[0, 0, 1]$

► Модель:  $\mathcal{P}(y = 1|x) = \frac{1}{1+e^{-(a_0+a_1x)}}$ ,

log loss:

$$\mathcal{L}(a_0, a_1) = - \sum_{i=1}^N (y_i \log(\mathcal{P}_i) + (1 - y_i) \log(1 - \mathcal{P}_i))$$

Градиенты:

$$\frac{\partial \mathcal{L}}{\partial a_0} = \sum_{i=1}^N (\mathcal{P}_i - y_i) \quad \frac{\partial \mathcal{L}}{\partial a_1} = \sum_{i=1}^N (\mathcal{P}_i - y_i) x_i$$

Инициализация:

$$\alpha = 0.1, a_0 = 0, a_1 = 0$$



# Пример

---

## ► 1 итерация:

- $\mathcal{P} = \frac{1}{1+e^0} = 0.5$

- $\mathcal{L} = -(0 \cdot \log(0.5) + 0 \cdot \log(0.5) + 1 \cdot \log(0.5)) = 0.693147$

- $\frac{\partial \mathcal{L}}{\partial a_0} = 0.1667 ; \frac{\partial \mathcal{L}}{\partial a_1} = 0$

- Новые веса:  $a_0 = a_0 - \alpha \frac{\partial \mathcal{L}}{\partial a_0} = -0.01667 ; a_1 = a_1 - \alpha \frac{\partial \mathcal{L}}{\partial a_1} = 0$

## ► 2 итерация:

- $\mathcal{P} = \frac{1}{1+e^{-0.1667}} = 0.4958$

- $\mathcal{L} = -(2 \cdot 0 \cdot \log(0.4958) + 1 \cdot \log(0.5042)) = 0.690404$

- Новые веса:  $a_0 = a_0 - \alpha \frac{\partial \mathcal{L}}{\partial a_0} = -0.03291 ;$

$$a_1 = a_1 - \alpha \frac{\partial \mathcal{L}}{\partial a_1} = 0.0008$$

# Пример

---

- ▶ После 500 итераций:
  - ▶  $\mathcal{P}_1 = 0.086$  ;  $\mathcal{P}_2 = 0.334$  ;  $\mathcal{P}_3 = 0.728$
  - ▶  $\mathcal{L} = 0.271315$
  - ▶  $a_0 = -4.0430$  ;  $a_1 = 1.6764$
  - ▶  $\mathcal{P}_1 < 0.5 \rightarrow x_1$  принадлежит классу 0;  
 $\mathcal{P}_2 < 0.5 \rightarrow x_2$  принадлежит классу 0;  
 $\mathcal{P}_3 > 0.5 \rightarrow x_3$  принадлежит классу 1.
  - ▶ Модель правильно классифицирует все три наблюдения

# Преимущества и недостатки

---

- ▶ **Преимущества:**

- ▶ Простая и понятная интерпретация
- ▶ Быстро обучается и не требует больших вычислений
- ▶ Предсказывает вероятность принадлежности
- ▶ Работает даже при небольших наборах данных

- ▶ **Недостатки:**

- ▶ Плохо справляется с нелинейными зависимостями
- ▶ Неустойчива к зависимым признакам

# Вариации и расширения

---

- ▶ **Мультиномиальная** — применяется, когда целевая переменная имеет три или более категорий.
- ▶ **Ординарная** — используется, когда целевая переменная имеет три или более порядковых категорий.
- ▶ Регуляризация (L1, L2)
- ▶ Часто служит финальным классификатором

# Источники

---

- ▶ Logistic Regression in Machine Learning
- ▶ Логистическая регрессия: что это простыми словами
- ▶ Логистическая, порядковая и мультиномиальная регрессия
- ▶ Исследование ординальных данных: Примеры и применение